

## 数据仓库课程报告

# ETL练习——获取电影数量

指导教师: 朱宏明

谭梓煊 (1853434) 刘文朔 (1851008)

Data Warehouse

Tongji University
School of Software Engineering

# 目录

- 一、项目概述
- 二、数据获取
  - A. 亚马逊电影评论数据集(开源)
  - B. 亚马逊25万商品数据(爬虫)

爬虫框架

反反爬虫

页面解析

最终结果

- 三、数据处理
  - 1. 开源评论数据集 -> 商品asin码列表

方案

注意事项

代码实现

输出

2. 原始商品数据 -> 电影数据

判断标准

多次筛选方法

3. 电影数据 -> 电影节点, 关系列表

实现思路

运行结果

4. 节点, 关系列表 -> 图数据库

四、总结

## 一、项目概述

- 近年来, 电影、DVD、歌剧等影像作品成为了人们生活中不可或缺的休闲消遣之物, 自电影于20世纪 初成规模时起, 在荧幕上出现过的影视作品数不胜数, 让想要从浩如烟海的影视作品中筛选出自己需 要的内容人们也变得举步维艰
- 在本次练习中, 我们使用Scrapy框架爬取了25万亚马逊商品页面, 使用Python脚本进行数据清洗和处理, 筛选出约20万电影数据, 提取出电影信息和电影之间的关联, 使用neo4j图数据库存储电影节点和电影之间的同类关系, 调用neo4j内置的图算法求解**弱连通分量**个数, 最终得到不同电影的总数约为12万
- 在爬虫设计中, 我们使用 <u>ProxyBroker</u> 工具作为ip代理池, 使用 <u>fake-useragent</u> 随机切换浏览器 UA, 并在此基础上通过设置请求速度等方式来突破Amazon的反爬虫机制。使用xpath和正则表达式来解析爬取到的html、提取商品信息, 使用 <u>isonlines</u> 格式存储网页解析后的数据
- 在数据清洗流程中,我们通过解析商品信息的几个特定属性进行判断,尽可能地将非电影的商品信息 去除而将电影的商品信息保留
- 最终将剩余信息按照节点和关系分别导出为CSV文件,导入neo4j中

## 二、数据获取

## A. 亚马逊电影评论数据集(开源)

- 亚马逊电影评论数据来自SNAP发布的 Web data: Amazon movie reviews 数据集. 该数据集包含了 跨度超过10年, 总数超过8百万条的亚马逊电影评论. 每条评论包括商品信息、用户信息、评分和纯 文本格式的评论内容.
- 该数据集采用纯文本格式保存,数据格式如下:

product/productId: B00006HAXW
review/userId: A1RSDE90N6RSZF

3 review/profileName: Joseph M. Kotow

4 review/helpfulness: 9/9

5 review/score: 5.0

6 review/time: 1042502400

7 review/summary: Pittsburgh - Home of the OLDIES

8 | review/text: I have all of the doo wop DVD's and this one is as good or

better than the

9 1st ones. Remember once these performers are gone, we'll never get to see

10 Rhino did an excellent job and if you like or love doo wop and Rock n Roll you'll LOVE

11 this DVD !!

数据集统计信息

| Catagory                       | value               |  |
|--------------------------------|---------------------|--|
| Number of reviews              | 7,911,684           |  |
| Number of users                | 889,176             |  |
| Number of products             | 253,059             |  |
| Users with > 50 reviews        | 16,341              |  |
| Median no. of words per review | 101                 |  |
| Timespan                       | Aug 1997 - Oct 2012 |  |

## B. 亚马逊25万商品数据(爬虫)

• 在亚马逊电影评论数据集中, 提取出所有商品asin码(见下文"数据处理1")之后, 即可开始构造爬虫爬取商品数据.

## 爬虫框架

- 我们使用了Scrapy框架进行数据爬取工作
- Scrapy框架包含了从请求发送到数据解析, 存储的整套流程, 具有强大的可定制性和可拓展性, 让开发者可以从复杂的错误处理, 频率控制等操作中脱离出来, 更加关注于整体流程.

## 反反爬虫

- 本次项目使用开源的 ProxyBroker 作为ip代理池
  - o ProxyBroker可以自动收集网络上可用的ip代理,并启动一个本地的代理服务器,将请求转发至这些ip代理处

```
proxybroker serve --host 127.0.0.1 --port 8888 --types HTTP HTTPS --lvl High

seport HTTP_PROXY=http://127.0.0.1:8888; export HTTPS_PROXY=http://127.0.0.1:8888 http http://httpbin.org/get\?show_env|
```

- 使用 fake-useragent 随机生成浏览器UserAgent
  - 。 将fake-useragent以中间件的形式集成到Scrapy框架中

```
1
    # @spider/amaspd/middlewares/UserAgentMiddleware.py
2
3
   from fake_useragent import UserAgent
4
5
   class UserAgentMiddleware:
6
7
        @classmethod
8
        def from_crawler(cls, crawler):
            # This method is used by Scrapy to create your spiders.
9
10
            return cls(crawler.settings)
11
        def __init__(self, settings):
12
13
            self.ua = UserAgent()
14
15
        def process_request(self, request, spider):
            request.headers['User-Agent'] = self.ua.random
16
```

。 然后在Scrapy的settings.py中添加中间件

```
DOWNLOADER_MIDDLEWARES = {
     'amaspd.middlewares.UserAgentMiddleware.UserAgentMiddleware': 502,
}
```

• 在请求头中添加一些header, 使得请求更像是浏览器发出的

```
headers = {
1
2
        'Accept':
    'text/html,application/xhtml+xml,application/xml;q=0.9,*/*;q=0.8',
        'Accept-Encoding': 'gzip, deflate, br',
3
        'Accept-Language': 'en-US,en;q=0.9,zh-CN;q=0.8,zh;q=0.7,zh-
4
    TW; q=0.6',
 5
 6
7
   # @settings.py
8
   DEFAULT_REQUEST_HEADERS = {
9
        'Upgrade-Insecure-Requests': 1,
10
        'Pragma': 'no-cache',
        'Cache-Control': 'no-cache',
11
12
    }
```

禁用Cookie

```
1 COOKIES_ENABLED = False
```

• 忽略Robot.txt

```
1 ROBOTSTXT_OBEY = False
```

• 控制发送请求的速度和频率,设置随机等待时间

```
1 CONCURRENT_REQUESTS = 16
2 DOWNLOAD_DELAY = 0.1
3 CONCURRENT_REQUESTS_PER_DOMAIN = 16
4 CONCURRENT_REQUESTS_PER_IP = 16
```

### 页面解析

- 在爬取过程中,我们发现Amazon电影页面整体分为两种样式,一种为黑色背景的Prime Video页面,另一种为白色背景的一般商品页. 对于这两种页面我们采用了不同的解析方法.
- 1. 对于Prime Video页面, 我们提取了如下三处信息
  - 1. html文档head标签中, 具有name="title"属性的meta标签信息

```
<meta name="title" content="Watch Colosseum - Rome's Arena of Death | Prime Video">
```

。 对应解析代码

```
1 | title = response.xpath('//meta[@name="title"]/@content').extract()[0]
```

2. 页面左侧的商品基本信息

```
Starring Jamel Aroui, Lotfi Dziri, Derek Lea
Genres Documentary
Subtitles English [CC]
Audio languages English
```

。 对应解析代码

```
primeMeta = {}

dts = response.xpath('//div[@id="meta-info"]//d1/dt')

for dt in dts:
    key = ''.join(dt.xpath('.//text()').extract())

value = ''.join(dt.xpath('../dd//text()').extract())

primeMeta[key] = value
```

3. 页面底部的Other formats列表

# Other formats DVD from \$7.00

o 对应解析代码

```
otherFormat = []
otherFormatHrefs = response.xpath('//div[@data-automation-id="other-formats"]//a/@href').extract()
for otherFormatHref in otherFormatHrefs:
    asin = re.search('/dp/(\w+)/', otherFormatHref).group(1)
    otherFormat.append(asin)
```

。 示例页面解析后的结果如下

```
1 {
 2
        "pid": "B003VHELLI",
 3
       "otherFormat": [
            "B00060BPZY"
 4
 5
        ],
        "title": "Watch Colosseum - Rome's Arena of Death | Prime Video",
 6
 7
        "primeMeta": {
            "Starring": "Jamel Aroui, Lotfi Dziri, Derek Lea",
 8
9
            "Genres": "Documentary",
            "Subtitles": "English [CC]",
10
            "Audio languages": "English"
11
12
        }
13 | }
```

- 2. 对于普通页面, 我们提取了四处信息
  - 1. html文档head标签中, 具有name="title"属性的meta标签信息

```
<meta name="title" content="Watch Colosseum - Rome's Arena of Death | Prime Video">
```

○ 对应解析代码

```
1 | title = response.xpath('//meta[@name="title"]/@content').extract()[0]
```

- 2. 页面顶部的Other formats列表
- 3. 页面顶部的Additional options列表

## Legend of Suram Fortress [VHS]

Format: VHS Tape

```
DVD
               VHS Tape
 $75.75
               $7.97
Additional VHS Tape options
                                Edition
                                                                    Discs
                                                                                        Price
                                                                                                           New from
                                                                                                                         Used from
  VHS Tape
                                                                                       $7.97
                                                                                                               $7.97
                                                                                                                            $14.99
  VHS Tape
                                                                                                                           $119.00
```

#### 。 对应解析代码

```
1
    otherFormat = []
 2
    otherFormatHrefs = response.xpath("//li[contains(@class,
    'swatchElement')]//a[@href!='javascript:void(0)']/@href").extract()
 3
   for otherFormatHref in otherFormatHrefs:
        asin = re.search('/dp/(w+)/', otherFormatHref).group(1)
 4
 5
        otherFormat.append(asin)
 6
 7
   additionalOptions = []
8
    additionalOptionHrefs = response.xpath("//div[contains(@class, 'top-
    level')]//span/@data-tmm-see-more-editions-click").extract()
    additionalOptionHrefs = list(filter(lambda x: '"metabindingUrl":"#"' not
    in x, additionalOptionHrefs))
   for additionalOptionHref in additionalOptionHrefs:
10
        asin = re.search('/dp/(w+)/', additionalOptionHref).group(1)
11
        additionalOptions.append(asin)
12
```

#### 4. 页面底部的Product details

#### **Product details**

Is Discontinued By Manufacturer: No
Package Dimensions: 7.32 x 4.19 x 1.12 inches; 6.13 Ounces
Media Format: Subtitled
ASIN: 5555223870

。 对应解析代码

```
productDetail = {}

detailNames =
    response.xpath('//div[@id="detailBullets_feature_div"]/ul[contains(@class
    , "detail-bullet-list")]//span[@class="a-text-bold"]')

for detailName in detailNames:
    key = detailName.xpath('.//text()').extract()[0][:-3]
    value = detailName.xpath('../span[last()]/text()').extract()[0]
    productDetail[key] = value
```

。 示例页面解析后的结果如下

```
1 {
2    "pid": "5555223870",
3    "otherFormat": [
4        "B01M6BGD6N",
5    ],
6    "title": "Amazon.com: Legend of Suram Fortress [VHS]: Movies & TV",
7    "productDetail": {
```

```
"Is Discontinued By Manufacturer": "No",
"Package Dimensions": "7.32 x 4.19 x 1.12 inches; 6.13 Ounces",
"Media Format": "Subtitled",
"ASIN": "5555223870"

},
"format": "VHS Tape",
"additionalOptions": ["B00004CL4G"]

}
```

### 最终结果

• 最终爬取速度约 120 item/min, 在爬取过程中发现有 1,391 个页面已经失效, 成功爬取到 251,668 条商品数据

## 三、数据处理

## 1. 开源评论数据集 -> 商品asin码列表

### 方案

• 逐行遍历movies.txt文件, 寻找开头为"product/productld:"的行, 提取后面的asin逐行写入到另一个文件中

## 注意事项

- movies.txt文件编码为"iso-8859-1", 如果编码选择不正确会导致数据错乱
- 使用集合数据结构存储已写入的asin防止重复

#### 代码实现

```
1 asinSet = set()
    with open("movies.txt", encoding="iso-8859-1") as movies, open('asin.txt',
    'w', encoding="utf-8") as f:
 3
        for line in movies:
 4
            trv:
 5
                asin = line.split("product/productId:")[1].strip()
                if asin not in asinSet:
 6
 7
                    asinSet.add(asin)
8
                    f.write(asin+'\n')
9
            except:
10
                pass
11
12
   print(f"Done. {len(asinSet)} asin in total")
```

#### 输出

```
1 B003AI2VGA
2 B00006HAXW
3 B00004CQT3
4 B00004CQT4
5 B006JIUN2W
6 B0078V2LCY
7 (...总计253059行,此结果与数据集说明相符)
```

## 2. 原始商品数据 -> 电影数据

• 得到原始商品数据后, 我们首先要进行数据清洗, 将非电影的商品信息去除

### 判断标准

- 我们仔细分析了亚马逊平台上的电影商品信息,找到了一些它们不同于非电影商品的共同点,以此为判断依据来分析一个商品是否是电影
- 1. 电影商品以及类电影商品(如纪录片)通常含有Director属性, 而多集电视剧一类的商品通常采用多导演拍摄, 因此信息中通常没有Director属性. 因此可以观察商品信息是否包含有Director属性, 如果出现则认为是电影
- 2. 商品信息中是否出现视频长度, 如果出现而且时长位于一定范围内则认为是电影
- 3. 商品信息中是否出现MPAA分级, 若有此属性且属性满足条件(不为NotRated一类的无意义分级), 则认为该商品是电影
- 4. 部分非电影商品的标题具有明显特征,如[VHS]为数字电视广播节目的录像, Analysis of ... technique为技术教程. 如标题为此类格式可以判断为非电影
- 5. 商品的Type/Genres属性表明了该出版物的体裁类型, 而部分属性很明显不是电影所有的, 比如 VHS、PBS(公共电视台节目)、fitness、TV Talk Shows、News一类. 若出现这些类型则可以直接判断为非电影
- 6. 否则认为商品不是电影
- 实际上使用简单的if-else判断法是称不上准确的,以上的任何一条判断法则都存在着例外,符合的不一定是电影,不符合的不一定不是电影。比如有些商品是时长超长的电影合集、部分带有TV类型的商品其实也是电影。以上判断法则只能说是一种倾向,即符合标准的我们相信它大概率确实是一部电影

## 多次筛选方法

- 可以使用以下方法来改进判断标准
- 1. 可以引入权重机制代替简单的if-else法. 比如若一个商品的Type为Reality TV, 则其的分数减少, 即减少其是电影的概率, 但不直接判断其不是电影. 最终根据商品的评分进行最终判断, 位于分界线附近的可以人工判断
- 2. 在检测的过程中, 若发现某些无关属性(如出版商、导演等)与商品的类型呈现强相关性, 则将其也加入权重判断中去. 比如若发现某公司出版商品全部都是电影, 则可以认为该公司比较偏爱于出版电影类商品, 若再发现该公司的商品则可以提升商品的电影权重
- 3. 相关属性也是同理, 若发现有商品的分类与其基于属性的判断冲突, 则认为该属性与商品的类型的相 关性并没有那么强, 可以削弱其权重
- 4. 判断完成后随机抽取几部人工判断, 根据2、3的法则进行权重的加减
- 5. 不断重复2~4的流程, 倾向特别大的可以直接判断, 根据判断结果改变权重, 依次循环, 直至剩余商品 少到可以人工判断为止
- 6. 如有条件可以构建神经网络模型, 使用Classifier分类器来进行判断

经过筛选, 最终得到了 201,368 条判断为电影的数据

## 3. 电影数据 -> 电影节点, 关系列表

 在数据清洗之后,我们得到了判断为电影的商品数据,接下来要从这些数据中提取出电影节点和电影 之间的关系.

### 实现思路

- 1. 提取节点
  - o 遍历所有电影的 otherFormat 和 additional Options 属性, 将未出现过的电影的asin提取出来, 和电影的名字一起逐行存储到一个csv文件中
  - o 如果遇到不在最初25万商品数据集合中的节点,则将标题设为"others"
- 2. 提取关系
  - o 遍历所有电影的 otherFormat 和 additional Options 属性, 将每一条关系逐行存储到一个csv文件中

#### 运行结果

• 节点列表

```
B01M6BFLSF,False,others
517201
           517202
517203
517204
517206
517207
517208
517209
            B0009S4IO2, True, Amazon.com: Real Wheels: Rockin' Real Wheels: Real Wheels: Movies & TV
            B01M6BCQZ9,False,others
517211
            B00UG07082, False, others
517212
            B01GWCHF7K,False,others
            B01M5ISP7P, False, others
            B003E74KRK,True, "Amazon.com: Word Is Out: Stories of Some of Our Lives: David Gillon, Sally Gearhart, Fred Gray, Dennis Chiu, Peter Adair 6302375746,False,others
517214
517216
            B00UGPUGPI.False.others
517217
            B01I06GFB8,False,others
517218
            B01M4QNMZD, False, others
            B003SIUNZA,True, "Amazon.com: Baseball: The Tenth Inning: ., Directed by Ken Burns and Lynn Novick: Movies & TV" B003SIUNZK,False,others
517219
517220
517221
            B0045VU87A, False, others
            B01M7X2JB0,False,others
517223
            B01M7X0GAR, False, others
           BOOMCAPACE, Talse, Others
6305839670, True, "Amazon.com: The Brigitte Bardot Collection (Come Dance With Me / Please Not Now / Les Femmes / Naughty Girl / Brigitte E
BOOJFZW7VC,True, "Amazon.com: Galloping Minds - Preschooler Learns Numbers and Counting with Animals: Galloping Minds, Galloping Minds: Mc
BOIMSIQ686,False, others
517224
517225
517226
517228
            B01M8PNC9K, False, others
            B004INI2IVQ,True, "Amazon.com: Fighting Mad / Moving Violation [Double Feature]: Stephen McHattie, Kay Lenz, Eddie Albert, Lonny Chapman, NB01GWC2H2I,False,others
517229
517230
            B01M5IMNH3,False,others
B01I063206,False,others
517231
517232
517233
            B00UGQKG8E, False, others
            BOOGSCUNIZU,True,"Amazon.com: Baseball: A Film by Ken Burns (Includes The Tenth Inning): Ken Burns, Ken Burns, Lynn Novick: Movies & TV"
BOOGGRUN4A,True,"Amazon.com: Savage Sinema From Down Under-3 dvd set: Kevin Hopkins, Mark Savage: Movies & TV"
6304952198,True,Amazon.com: Journey to the Hollow Earth [VHS]: Journey to the Hollow Earth: Movies & TV
517234
517235
517236
517237
```

#### • otherFormat关系列表

```
B00008G1YG,630427405X
242621
           B004GE2PMM,B003YCL15C
           B000MDD6XI,B003J216K0
242623
           B000MDD6XI,B004VDSWXE
242624
           B000MDD6XI,B01LW5BM5U
242625
           B00004CKFK,B074TQTGR2
242626
           B00004CKFK,B00CL91120
           B00004CKFK, B00008MTXR
242628
           B00004CKFK, B0080GEV0G
242629
242630
           B00008G8TX,B00029NLG4
B00015XDV0,B07P7227QB
242631
           B000I5XDV0,B009DT9DIY
           B000I5XDV0,B000LSAJ34
242633
           B003SNJY1C,B0081LMRBU
242634
242635
           B001NOMOT2,B009B8YMB0
B001NOMOT2,B009B8YMHO
           B0001I55PG,B003XCH136
B0001I55PG,0788812483
242636
242637
242638
           B0001I55PQ,B003Y68NGA
242639
           B0001I55PQ,B00000JMQH
           6300208915,B0051WTMXS
242640
           6301966279,B000NV2Q9Y
6301966279,B0851KK5T5
242641
242642
242643
           B001VLBDEE,B087H1JHLS
242644
           B0050QNO2U,B005FDW5N2
242645
           B000W950Y6, B0040SPKAY
           B000W950Y6,B000006BTD
6304026668,B0081AIGV6
242646
242647
242648
           6304026668,B0002HS17U
           B0001I55P6,B003V5K12S
242649
242650
           B0001I55P6,6300275825
242651
           B003E74KRK,6302375746
242652
           B003S1UNZA,B003S1UNZK
242653
242654
           6305839670,6305839867
B003S1UNZU,6303218725
242655
           6304952198,B0007US85M
```

• additionalOptions关系列表

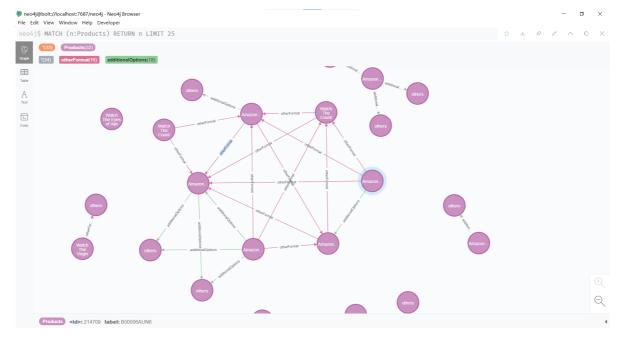
```
552724 6304026668,630402617X
           6304026668,6304725019
6304026668,B00004REK7
           6304026668,B00004CJ6H
B0001I55P6,B01I067V0M
552727
552729
           B0001I55P6,B00003L9BZ
            B0009S4I02,B01M6BCQZ9
552731
            B0009S4I02,B00UGQ7Q82
552732
552733
           B0009S4IO2,B01GWCHF7K
B0009S4IO2,B01M5ISP7P
552734
            B003E74KRK,B00UGPUGPI
            B003E74KRK,B01I06GFB
552736
            B003E74KRK,B01M4QNMZD
552737
552738
           B003S1UNZA,B0045VU87A
B003S1UNZA,B01M7X2JB0
552739
            B003S1UNZA,B01M7X0GAR
            B003S1UNZA,B00UGPRPE8
552741
            B003FZW7VC,B01M5IOG86
552742
552743
           B003FZW7VC,B01M8PNC9K
B004IN21VQ,B01GWC2H2I
           B004IN21VQ,B01M5IMNH3
B004IN21VQ,B01I063206
552744
552746
            B004IN21VO,B00UGOKG8E
552747
552748
           B003S1UNZU,B01GWCKCJS
B003S1UNZU,B003XEKXY8
552749
552750
           B003S1UNZU,B076F6VMV7
B003S1UNZU,B000NKRJLU
552751
            B003S1UNZU,B01GWC0I0M
            B003S1UNZU,B0002KPI28
552753
            B003S1UNZU,0780630459
552754
552755
           B003S1UNZU,B006YJ6Z3C
B003S1UNZU,B01M4QNQK5
552756
            B003S1UNZU,B000NKNSUO
552758
            B003S1UNZU,B000BITUDO
552759
            B003S1UNZU,B000NKKNCC
```

## 4. 节点, 关系列表 -> 图数据库

• 得到节点和关系之后,即可导入neo4j数据库进行计算

```
1 // 导入节点
   :auto USING PERIODIC COMMIT
   LOAD CSV WITH HEADERS FROM "file:///node.csv" AS line
4 | CREATE (p:Products{label:line.label,title:line.title})
5
6
   // 导入otherFormat关系
7
   :auto USING PERIODIC COMMIT
8
   LOAD CSV WITH HEADERS FROM "file:///otherFormat.csv" AS line
9
   MATCH (from:Products{label:line.label1}), (to:Products{label:line.label2})
10
   MERGE (from)-[:otherFormat]-(to)
11
12
   // 导入additionalOptions关系
13
   :auto USING PERIODIC COMMIT
14 LOAD CSV WITH HEADERS FROM "file:///additionalOptions.csv" AS line
15 | MATCH (from:Products{label:line.label1}), (to:Products{label:line.label2})
16
   MERGE (from)-[:additionalOptions]-(to)
```

• 导入成功后,即可在Neo4j Browser中看到数据库中存储的节点和节点之间的关系



• 最后调用Neo4j的图算法库

```
1 // 创建一个图
    CALL gds.graph.create.cypher(
 3
        'mygraph',
        'MATCH (n:Products) RETURN id(n) AS id',
4
        'MATCH (a:Products)-->(b:Products) RETURN id(a) AS source, id(b) AS
    target'
6
   )
7
    YIELD graphName, nodeCount, relationshipCount, createMillis;
8
   // 计算wcc(弱连通分量)
9
10 CALL gds.wcc.stats('mygraph')
11
    YIELD componentCount
```



• 即可得到最终结果,说明在25万条商品信息中一共出现了117,514部不同的电影

# 四、总结

本项目中, 我们通过开源数据集与Amazon网站爬取的商品数据, 完整地进行了数据的获取、数据的ETL和预处理。