同济大学 TONGJI UNIVERSITY

October 25, 2020
版本: 1.0

数据仓库课程报告

ETL练习——获取电影数量

指导教师: **朱宏明**

谭梓煊 *(1853434)*
刘文朔 *(1851008)*

Data Warehouse

Tongji University
School of Software Engineering

目录

一、项目概述

- 近年来, 电影、DVD、歌剧等影像作品成为了人们生活中不可或缺的休闲消遣之物, 自电影于20世纪初成规模时起, 在荧幕上出现过的影视作品数不胜数, 让想要从浩如烟海的影视作品中筛选出自己需要的内容人们也变得举步维艰, 因此我们设想设计一个能够支持复杂条件查询, 大数据的电影信息系统
- 在本次练习中, 我们使用Scrapy框架爬取了25万亚马逊商品页面, 使用Python脚本进行数据清洗和处理, 筛选出约20万电影数据, 提取出电影信息和电影之间的关联, 使用neo4j图数据库存储电影节点和电影之间的同类关系, 调用neo4j内置的图算法求解**弱连通分量**个数, 最终得到不同电影的总数约为12万
- 在爬虫设计中, 我们使用 ProxyBroker 工具作为ip代理池, 使用 fake-useragent 随机切换浏览器UA, 并在此基础上通过设置请求速度等方式来突破Amazon的反爬虫机制。使用xpath和正则表达式来解析爬取到的html、提取商品信息, 使用 jsonlines 格式存储网页解析后的数据
- 在数据清洗流程中, 我们通过解析商品信息的几个特定属性进行判断, 尽可能地将非电影的商品信息去除而将电影的商品信息保留
- 最终, 我们将剩余信息按照节点和关系分别导出为CSV文件, 使用neo4j图数据库来处理信息

二、数据获取

A. 亚马逊电影评论数据集(开源)

- 亚马逊电影评论数据来自SNAP发布的 Web data: Amazon movie reviews 数据集. 该数据集包含了跨度超过10年, 总数超过8百万条的亚马逊电影评论. 每条评论包括商品信息、用户信息、评分和纯文本格式的评论内容.
- 该数据集采用纯文本格式保存, 数据格式如下:

```
product/productId: B00006HAXW
review/userId: A1RSDE90N6RSZF
review/profileName: Joseph M. Kotow
review/helpfulness: 9/9
review/score: 5.0
review/time: 1042502400
review/summary: Pittsburgh - Home of the OLDIES
review/text: I have all of the doo wop DVD's and this one is as good or better than the
1st ones. Remember once these performers are gone, we'll never get to see them again.
Rhino did an excellent job and if you like or love doo wop and Rock n Roll you'll LOVE
this DVD !!
```

- 数据集统计信息

Catagory	value
Number of reviews	7,911,684
Number of users	889,176
Number of products	**253,059**
Users with > 50 reviews	16,341
Median no. of words per review	101
Timespan	Aug 1997 - Oct 2012

B. 亚马逊25万商品数据(爬虫)

- 在亚马逊电影评论数据集中, 提取出所有商品asin码(见下文"数据处理1")之后, 即可开始构造爬虫爬取商品数据.

爬虫框架

- 我们使用了Scrapy框架进行数据爬取工作
- Scrapy框架包含了从请求发送到数据解析, 存储的整套流程, 具有强大的可定制性和可拓展性, 让开发者可以从复杂的错误处理, 频率控制等操作中脱离出来, 更加关注于整体流程.

反反爬虫

- 本次项目使用开源的 ProxyBroker 作为ip代理池
    - ProxyBroker可以自动收集网络上可用的ip代理, 并启动一个本地的代理服务器, 将请求转发至这些ip代理处

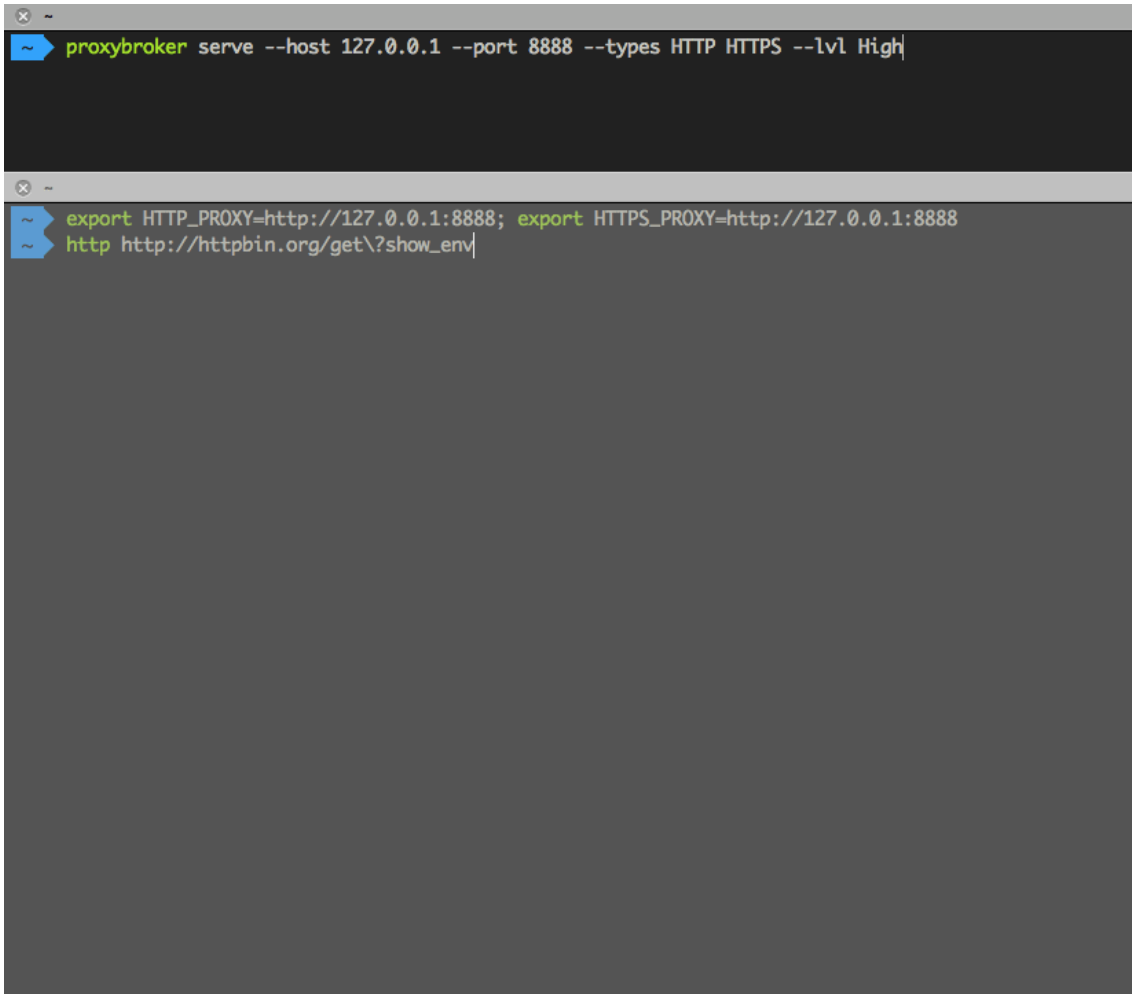

- 使用 fake-useragent 随机生成浏览器UserAgent
  - 将fake-useragent以中间件的形式集成到Scrapy框架中

```python
# @spider/amaspd/middlewares/UserAgentMiddleware.py

from fake_useragent import UserAgent

class UserAgentMiddleware:

    @classmethod
    def from_crawler(cls, crawler):
        # This method is used by Scrapy to create your spiders.
        return cls(crawler.settings)

    def __init__(self, settings):
        self.ua = UserAgent()

    def process_request(self, request, spider):
        request.headers['User-Agent'] = self.ua.random
```

  - 然后在Scrapy的settings.py中添加中间件

```python
DOWNLOADER_MIDDLEWARES = {
    'amaspd.middlewares.UserAgentMiddleware.UserAgentMiddleware': 502,
}
```

- 在请求头中添加一些header, 使得请求更像是浏览器发出的

```
headers = {
    'Accept':
'text/html,application/xhtml+xml,application/xml;q=0.9,*/*;q=0.8',
    'Accept-Encoding': 'gzip, deflate, br',
    'Accept-Language': 'en-US,en;q=0.9,zh-CN;q=0.8,zh;q=0.7,zh-
TW;q=0.6',
}

# @settings.py
DEFAULT_REQUEST_HEADERS = {
    'Upgrade-Insecure-Requests': 1,
    'Pragma': 'no-cache',
    'Cache-Control': 'no-cache',
}
```

- 禁用Cookie

```
COOKIES_ENABLED = False
```

- 忽略Robot.txt

```
ROBOTSTXT_OBEY = False
```

- 控制发送请求的速度和频率, 设置随机等待时间

```
CONCURRENT_REQUESTS = 16
DOWNLOAD_DELAY = 0.1
CONCURRENT_REQUESTS_PER_DOMAIN = 16
CONCURRENT_REQUESTS_PER_IP = 16
```

页面解析

- 在爬取过程中, 我们发现Amazon电影页面整体分为两种样式, 一种为黑色背景的Prime Video页面, 另一种为白色背景的一般商品页. 对于这两种页面我们采用了不同的解析方法.

1. 对于Prime Video页面, 我们提取了如下三处信息
    1. html文档head标签中, 具有name="title"属性的meta标签信息

```
<meta name="title" content="Watch Colosseum - Rome's Arena of Death | Prime Video">
```

    - 对应解析代码

```
title = response.xpath('//meta[@name="title"]/@content').extract()[0]
```

    2. 页面左侧的商品基本信息

    - 对应解析代码

```
primeMeta = {}
dts = response.xpath('//div[@id="meta-info"]//dl/dt')
for dt in dts:
    key = ''.join(dt.xpath('.//text()').extract())
    value = ''.join(dt.xpath('../dd//text()').extract())
    primeMeta[key] = value
```

3. 页面底部的Other formats列表

- 对应解析代码

```
otherFormat = []
otherFormatHrefs = response.xpath('//div[@data-automation-id="other-formats"]//a/@href').extract()
for otherFormatHref in otherFormatHrefs:
    asin = re.search('/dp/(\w+)/', otherFormatHref).group(1)
    otherFormat.append(asin)
```

- 示例页面解析后的结果如下

```
{
    "pid": "B003VHELLI",
    "otherFormat": [
        "B0006OBPZY"
    ],
    "title": "Watch Colosseum - Rome's Arena of Death | Prime Video",
    "primeMeta": {
        "Starring": "Jamel Aroui, Lotfi Dziri, Derek Lea",
        "Genres": "Documentary",
        "Subtitles": "English [CC]",
        "Audio languages": "English"
    }
}
```

2. 对于普通页面, 我们提取了四处信息
    1. html文档head标签中, 具有name="title"属性的meta标签信息

```
<meta name="title" content="Watch Colosseum - Rome's Arena of Death | Prime Video">
```

- 对应解析代码

```
title = response.xpath('//meta[@name="title"]/@content').extract()[0]
```

    2. 页面顶部的Other formats列表
    3. 页面顶部的Additional options列表

- 对应解析代码

```
otherFormat = []
otherFormatHrefs = response.xpath("//li[contains(@class, 'swatchElement')]//a[@href!='javascript:void(0)']/@href").extract()
for otherFormatHref in otherFormatHrefs:
    asin = re.search('/dp/(\w+)/', otherFormatHref).group(1)
    otherFormat.append(asin)

additionalOptions = []
additionalOptionHrefs = response.xpath("//div[contains(@class, 'top-level')]//span/@data-tmm-see-more-editions-click").extract()
additionalOptionHrefs = list(filter(lambda x: '"metabindingUrl":"#"' not in x, additionalOptionHrefs))
for additionalOptionHref in additionalOptionHrefs:
    asin = re.search('/dp/(\w+)/', additionalOptionHref).group(1)
    additionalOptions.append(asin)
```

4. 页面底部的Product details

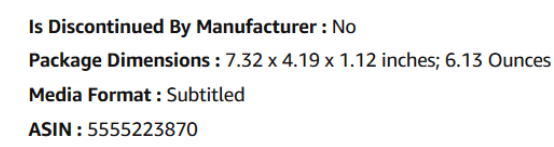

- 对应解析代码

```
productDetail = {}
detailNames = response.xpath('//div[@id="detailBullets_feature_div"]/ul[contains(@class, "detail-bullet-list")]//span[@class="a-text-bold"]')
for detailName in detailNames:
    key = detailName.xpath('.//text()').extract()[0][:-3]
    value = detailName.xpath('../span[last()]/text()').extract()[0]
    productDetail[key] = value
```

- 示例页面解析后的结果如下

```
{
    "pid": "5555223870",
    "otherFormat": [
        "B01M6BGD6N",
    ],
    "title": "Amazon.com: Legend of Suram Fortress [VHS]: Movies & TV",
    "productDetail": {
```

```
        "Is Discontinued By Manufacturer": "No",
        "Package Dimensions": "7.32 x 4.19 x 1.12 inches; 6.13 Ounces",
        "Media Format": "Subtitled",
        "ASIN": "5555223870"
    },
    "format": "VHS Tape",
    "additionalOptions": ["B00004CL4G"]
}
```

最终结果

- 最终爬取速度约 120 item/min, 在爬取过程中发现有 1,391 个页面已经失效, 成功爬取到 251,668 条商品数据

三、数据处理

1. 开源评论数据集 -> 商品asin码列表

方案

- 逐行遍历movies.txt文件, 寻找开头为"product/productId:"的行, 提取后面的asin逐行写入到另一个文件中

注意事项

- movies.txt文件编码为"iso-8859-1", 如果编码选择不正确会导致数据错乱
- 使用集合数据结构存储已写入的asin防止重复

代码实现

```
asinSet = set()
with open("movies.txt", encoding="iso-8859-1") as movies, open('asin.txt', 'w', encoding="utf-8") as f:
    for line in movies:
        try:
            asin = line.split("product/productId:")[1].strip()
            if asin not in asinSet:
                asinSet.add(asin)
                f.write(asin+'\n')
        except:
            pass

print(f"Done. {len(asinSet)} asin in total")
```

输出

```
B003AI2VGA
B00006HAXW
B00004CQT3
B00004CQT4
B006JIUN2W
B0078V2LCY
(...总计253059行, 此结果与数据集说明相符)
```

2. 原始商品数据 -> 电影数据

- 得到原始商品数据后, 我们首先要进行数据清洗, 将非电影的商品信息去除

判断标准

- 我们仔细分析了亚马逊平台上的电影商品信息, 找到了一些它们不同于非电影商品的共同点, 以此为判断依据来分析一个商品是否是电影

1. 电影商品以及类电影商品(如纪录片)通常含有Director属性, 而多集电视剧一类的商品通常采用多导演拍摄, 因此信息中通常没有Director属性. 因此可以观察商品信息是否包含有Director属性, 如果出现则认为是电影
2. 商品信息中是否出现视频长度, 如果出现而且时长位于一定范围内则认为是电影
3. 商品信息中是否出现MPAA分级, 若有此属性且属性满足条件(不为NotRated一类的无意义分级), 则认为该商品是电影
4. 部分非电影商品的标题具有明显特征, 如[VHS]为数字电视广播节目的录像, Analysis of ... technique为技术教程. 如标题为此类格式可以判断为非电影
5. 商品的Type/Genres属性表明了该出版物的体裁类型, 而部分属性很明显不是电影所有的, 比如VHS、PBS(公共电视台节目)、fitness、TV Talk Shows、News一类. 若出现这些类型则可以直接判断为非电影
6. 否则认为商品不是电影

- 实际上使用简单的if-else判断法是称不上准确的, 以上的任何一条判断法则都存在着例外, 符合的不一定是电影, 不符合的不一定不是电影. 比如有些商品是时长超长的电影合集、部分带有TV类型的商品其实也是电影. **以上判断法则只能说是一种倾向, 即符合标准的我们相信它大概率确实是一部电影**

进阶方法

- 可以使用以下方法来改进判断标准

1. 可以引入权重机制代替简单的if-else法. 比如若一个商品的Type为Reality TV, 则其的分数减少, 即减少其是电影的概率, 但不直接判断其不是电影. 最终根据商品的评分进行最终判断, 位于分界线附近的可以人工判断
2. 在检测的过程中, 若发现某些无关属性(如出版商、导演等)与商品的类型呈现强相关性, 则将其也加入权重判断中去. 比如若发现某公司出版商品全部都是电影, 则可以认为该公司比较偏爱于出版电影类商品, 若再发现该公司的商品则可以提升商品的电影权重
3. 相关属性也是同理, 若发现有商品的分类与其基于属性的判断冲突, 则认为该属性与商品的类型的相关性并没有那么强, 可以削弱其权重
4. 判断完成后随机抽取几部人工判断, 根据2、3的法则进行权重的加减
5. 不断重复2~4的流程, 倾向特别大的可以直接判断, 根据判断结果改变权重, 依次循环, 直至剩余商品少到可以人工判断为止
6. 如有条件可以构建神经网络模型, 使用Classifier分类器来进行判断

经过筛选, 最终得到了 201,368 条判断为电影的数据

3. 电影数据 -> 电影节点, 关系列表

- 在数据清洗之后, 我们得到了判断为电影的商品数据, 接下来要从这些数据中提取出电影节点和电影之间的关系.

实现思路

1. 提取节点
    - 遍历所有电影的`otherFormat`和`additionalOptions`属性, 将未出现过的电影的asin提取出来, 和电影的名字一起逐行存储到一个csv文件中
    - 如果遇到不在最初25万商品数据集合中的节点, 则将标题设为"others"
2. 提取关系
    - 遍历所有电影的`otherFormat`和`additionalOptions`属性, 将每一条关系逐行存储到一个csv文件中

运行结果

- 节点列表

node.csv

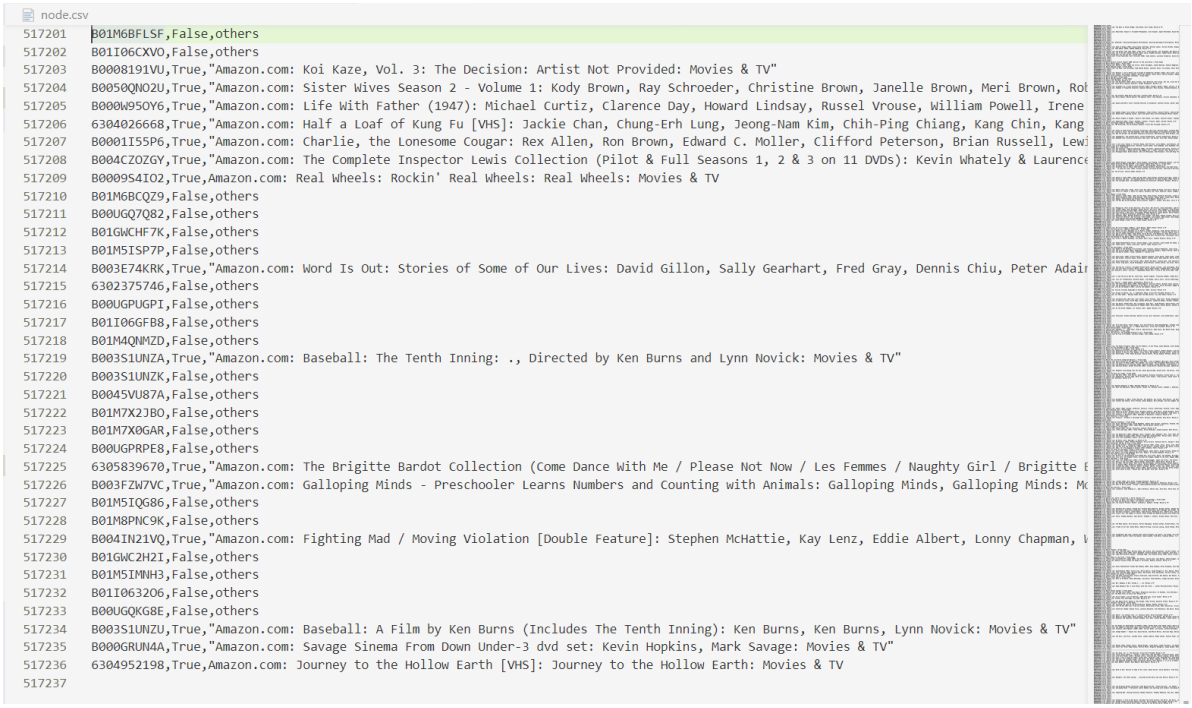

```
B01M6BFLSF,False,others
B01I06CXVO,False,others
B0008191VU,True,"Amazon.com: Koi Kaze, Vol. 3: The Decision: Artist Not Provided: Movies & TV"
B0050QNO2U,True,"Amazon.com: Sister Wives Season 2 - Volume 1: Kody Brown, Ray Schroeder, Christine Brown, Janelle Brown, Meri Brown, Rob
B000W95OY6,True,"Amazon.com: Life With Father (1947): Michael Curtiz, Clarence Day, Howard Lindsay, Russel Vrouse, William Powell, Irene
6304026668,True,"Amazon.com: Half a Loaf of Kung Fu [VHS]: Jackie Chan, Chung-Erh Lung, Jeong-Nam Kim, Chih-Ping Chiang, Kang Chin, Kang
B0001I55P6,True,"Amazon.com: Charlie, the Lonesome Cougar: Rex Allen, Ron Brown, Edward C. Moller, Clifford Peterson, Brian Russell, Lewi
B004CZOZGY,True,"Amazon.com: The Complete Inspector Lewis Collection (Pilot & Full Seasons 1, 2 & 3 on 11 DVDs): Kevin Whately & Laurence
B0009S4IO2,True,Amazon.com: Real Wheels: Rockin' Real Wheels: Real Wheels: Movies & TV
B01M6BCQZ9,False,others
B00UGQ7Q82,False,others
B01GWCHF7K,False,others
B01M5ISP7P,False,others
B003E74KRK,True,"Amazon.com: Word Is Out: Stories of Some of Our Lives: David Gillon, Sally Gearhart, Fred Gray, Dennis Chiu, Peter Adair
6302375746,False,others
B00UGPUGPI,False,others
B01I06GFB8,False,others
B01M4QNMZD,False,others
B003S1UNZA,True,"Amazon.com: Baseball: The Tenth Inning: ., Directed by Ken Burns and Lynn Novick: Movies & TV"
B003S1UNZK,False,others
B0045VU87A,False,others
B01M7X2JBO,False,others
B01M7X0GAR,False,others
B00UGPRPE8,False,others
6305839670,True,"Amazon.com: The Brigitte Bardot Collection (Come Dance With Me / Please Not Now / Les Femmes / Naughty Girl / Brigitte E
B003FZW7VC,True,"Amazon.com: Galloping Minds - Preschooler Learns Numbers and Counting with Animals: Galloping Minds, Galloping Minds: Mc
B01M5IQG86,False,others
B01M8PNC9K,False,others
B004IN21VQ,True,"Amazon.com: Fighting Mad / Moving Violation [Double Feature]: Stephen McHattie, Kay Lenz, Eddie Albert, Lonny Chapman, W
B01GWC2H2I,False,others
B01M5IMNH3,False,others
B01I0632O6,False,others
B00UGQKG8E,False,others
B003S1UNZU,True,"Amazon.com: Baseball: A Film by Ken Burns (Includes The Tenth Inning): Ken Burns, Ken Burns, Lynn Novick: Movies & TV"
B000GRUN4A,True,"Amazon.com: Savage Sinema From Down Under-3 dvd set: Kevin Hopkins, Mark Savage: Movies & TV"
6304952198,True,Amazon.com: Journey to the Hollow Earth [VHS]: Journey to the Hollow Earth: Movies & TV

```

- otherFormat关系列表

otherFormat.csv

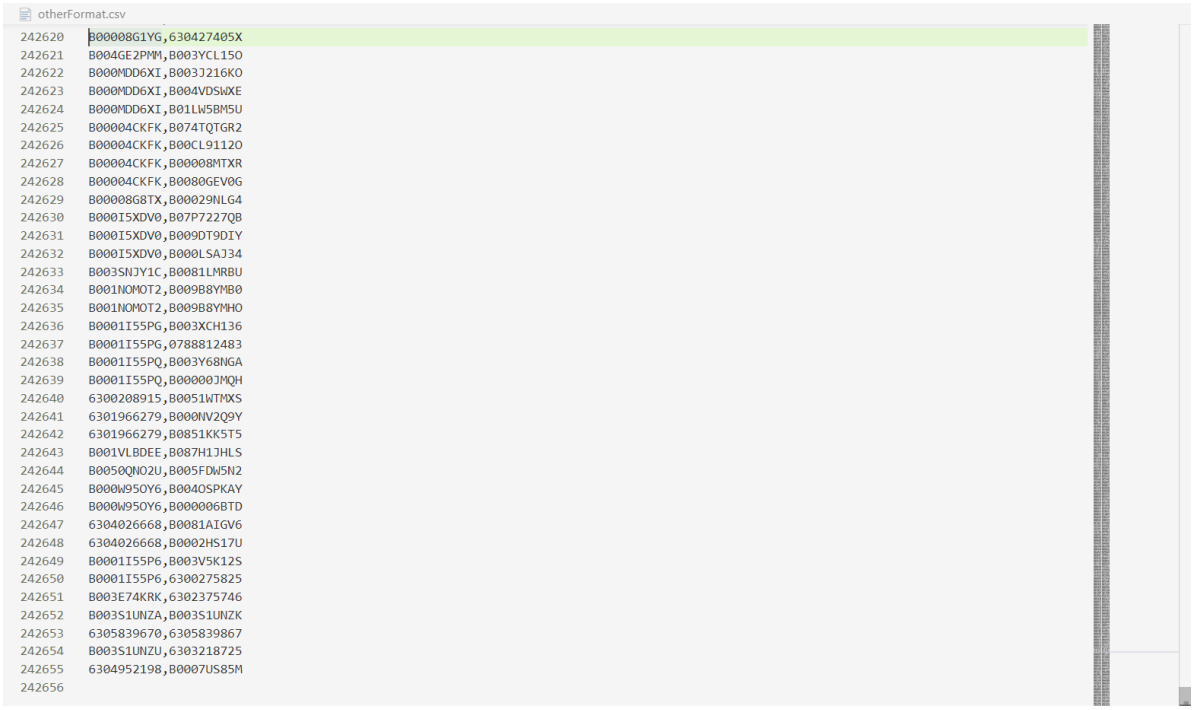

```
B00008G1YG,630427405X
B004GE2PMM,B003YCL15O
B000MDD6XI,B003J216KO
B000MDD6XI,B004VDSWXE
B000MDD6XI,B01LW5BM5U
B00004CKFK,B074TQTGR2
B00004CKFK,B00CL9112O
B00004CKFK,B00008MTXR
B00004CKFK,B0080GEV0G
B00008G8TX,B00029NLG4
B000I5XDV0,B07P7227QB
B000I5XDV0,B009DT9DIY
B000I5XDV0,B000LSAJ34
B003SNJY1C,B0081LMRBU
B001NOMOT2,B009B8YMB0
B001NOMOT2,B009B8YMHO
B0001I55PG,B003XCH136
B0001I55PG,0788812483
B0001I55PQ,B003Y68NGA
B0001I55PQ,B00000JMQH
6300208915,B0051WTMXS
6301966279,B000NV2Q9Y
6301966279,B0851KK5T5
B001VLBDEE,B087H1JHLS
B0050QNO2U,B005FDW5N2
B000W95OY6,B004OSPKAY
B000W95OY6,B000006BTD
6304026668,B0081AIGV6
6304026668,B0002HS17U
B0001I55P6,B003V5K12S
B0001I55P6,6300275825
B003E74KRK,6302375746
B003S1UNZA,B003S1UNZK
6305839670,6305839867
B003S1UNZU,6303218725
6304952198,B0007US85M

```

- additionalOptions关系列表

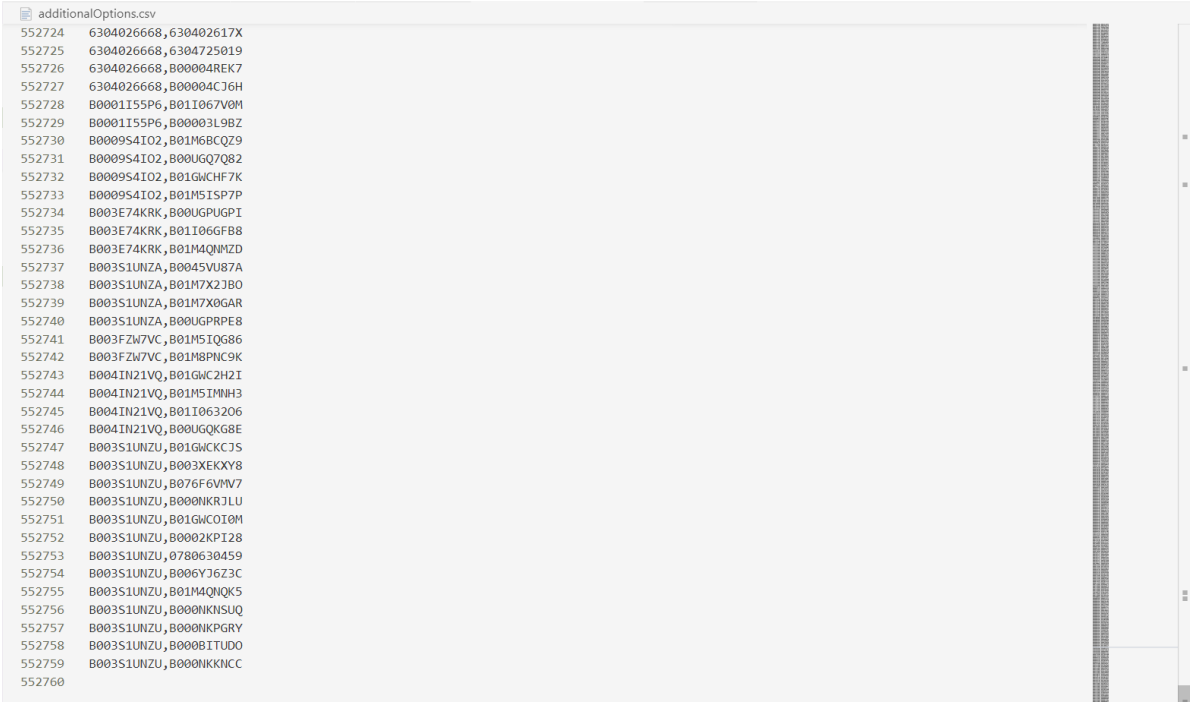

4. 节点, 关系列表 -> 图数据库

- 得到节点和关系之后, 即可导入neo4j数据库进行计算

```
// 导入节点
:auto USING PERIODIC COMMIT
LOAD CSV WITH HEADERS FROM "file:///node.csv" AS line
CREATE (p:Products{label:line.label,title:line.title})

// 导入otherFormat关系
:auto USING PERIODIC COMMIT
LOAD CSV WITH HEADERS FROM "file:///otherFormat.csv" AS line
MATCH (from:Products{label:line.label1}), (to:Products{label:line.label2})
MERGE (from)-[:otherFormat]-(to)

// 导入additionalOptions关系
:auto USING PERIODIC COMMIT
LOAD CSV WITH HEADERS FROM "file:///additionalOptions.csv" AS line
MATCH (from:Products{label:line.label1}), (to:Products{label:line.label2})
MERGE (from)-[:additionalOptions]-(to)
```

- 导入成功后, 即可在Neo4j Browser中看到数据库中存储的节点和节点之间的关系

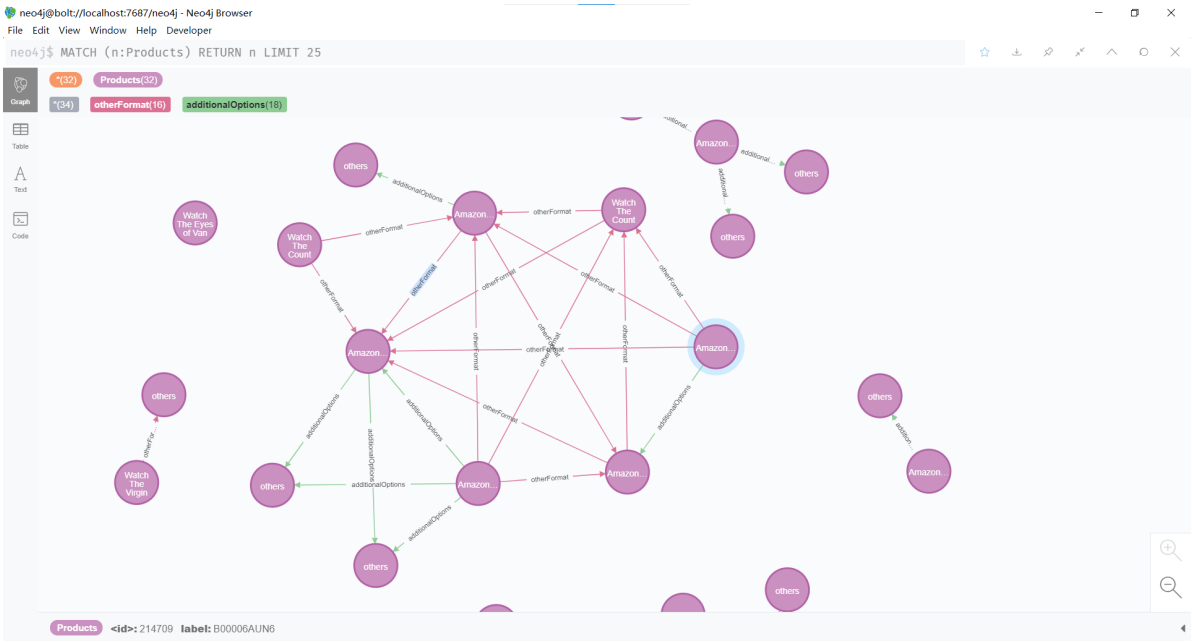

- 最后调用Neo4j的图算法库

```
// 创建一个图
CALL gds.graph.create.cypher(
    'mygraph',
    'MATCH (n:Products) RETURN id(n) AS id',
    'MATCH (a:Products)-->(b:Products) RETURN id(a) AS source, id(b) AS target'
)
YIELD graphName, nodeCount, relationshipCount, createMillis;

// 计算wcc(弱连通分量)
CALL gds.wcc.stats('mygraph')
YIELD componentCount
```

- 即可得到最终结果, 说明在25万条商品信息中一共出现了 117,514 部不同的电影

四、总结

本项目中, 我们通过开源数据集与Amazon网站爬取的商品数据, 完整地进行了数据的获取、数据的ETL和预处理。